

A dark blue vertical bar on the left side of the slide. A blue arrow points to the right from the bar, containing the date.

04/02/2022

PMI :

Etat de santé des structures composites avec Machine Learning

Several thin, curved lines in dark blue and light grey originate from the bottom left and curve upwards and to the right.

Florian Cataldi, Clément Jegouzo, Alexandre Thelliez

Table des matières

I – ETAT DE L’ART DU PROJET	2
1) Les matériaux composites	2
2) Etat de santé des structures	5
3) L’intelligence artificielle	8
a) Le machine learning	8
b) Le deep learning.....	11
II - ETABLIR UNE BASE DE DONNÉES	13
1) Les matériaux Composites	13
2) Notre matériau composite.....	14
3) La construction de l’expérience	15
4) Les cracks	17
5) Les modes et fréquences	19
6) Les résultats	20
7) La base de données.....	21
8) Pour aller plus loin	22
III – L’INTELLIGENCE ARTIFICIELLE	23
1) Le choix de l’architecture.....	23
2) Perceptron	25
3) Arbre de décision	27
Conclusion.....	30

I – ETAT DE L'ART DU PROJET

Pour composer l'état de l'art du sujet nous extrayons les trois mots-clés du titre du sujet : les matériaux composites, l'état de santé des structures et le machine learning. Dans cette partie nous allons donc présenter ces trois notions

1) Les matériaux composites

Un élément composite est une combinaison de deux matériaux pour former une autre structure de matériaux qui aurait des propriétés différentes de si les éléments étaient seuls. Ils peuvent avoir des caractéristiques différentes comme de la résistance à la corrosion, absorption des chocs, être plus léger, résistance à la température, etc. Nous aborderons quelques détails sur les composites dans la seconde partie. On utilise généralement un matériau composite avec une caractéristique particulière pour un environnement spécifique. Les matériaux composites sont cependant très utilisés dans l'industrie. L'industrie aéronautique en est le meilleur exemple. En effet, pour des raisons économiques l'utilisation des matériaux composites augmente contrairement à celle des alliages métalliques. La raison principale raison est la caractéristique de la réduction du poids. Dans une compagnie aéronautique civil, moins de poids implique moins de carburant, plus de chargement (fret ou passager) ce qui finalement rapporte plus d'argent et permet d'être un peu plus écologique. Du côté militaire, la réduction du poids permet de charger plus les avions en hommes et en matériels, de plus des manœuvres plus complexes peuvent être réalisées.




Figure 1 : Compositions d'un Boeing 787

Pour illustrer les propos précédent nous pouvons voir ci-dessus (Figure 1) la composition des différents matériaux dans un appareil Boeing 787, où nous pouvons voir que 50% du poids des matériaux de l'avion est due aux matériaux composites, seulement 20% pour l'aluminium. Le Boeing 777 était lui composé de 12% de matériaux composites et de 50% d'aluminium, ce qui montre l'évolution de l'utilisation des matériaux composites.

De plus, pour montrer cette évolution nous allons prendre cette fois ci l'exemple d'airbus. Comme vous pouvez le voir sur la Figure 2 au fur et à mesure des années les appareils airbus sont composés de plus en plus de matériaux composites. L'A300 a un poids de structure due aux composites de 5% dans les années 70, on passe alors vers les 13% avec l'A340-600 en

2000. En 2005, l'A380 est à 25% de composite et un peu plus tard l'A400M a 30%. Tout cela pour atteindre les 40% de matériaux composites en 2010 avec l'A350.

Les industries s'intéressent de plus en plus aux matériaux composites sandwich grâce à ces hautes performances. Généralement, un noyau léger et épais et entouré de deux fines couches rigides. Les deux peaux, également appelées feuilles de surface, ont des propriétés matérielles et géométriques identiques. Dans les structures sandwich composites, les feuilles de surface sont fabriquées à partir de plis stratifiés avec une séquence d'empilement spécifiée à des fins spécifiques, qui peuvent résister aux charges dans le plan et en flexion. L'âme, de forme régulière ou en mousse, comme le montre la figure 3, peut résister à une charge de cisaillement transversal et possède des propriétés différentes selon la configuration.




Figure 2 : Compositions en matériaux composites des appareils Airbus entre 1970 et 2010

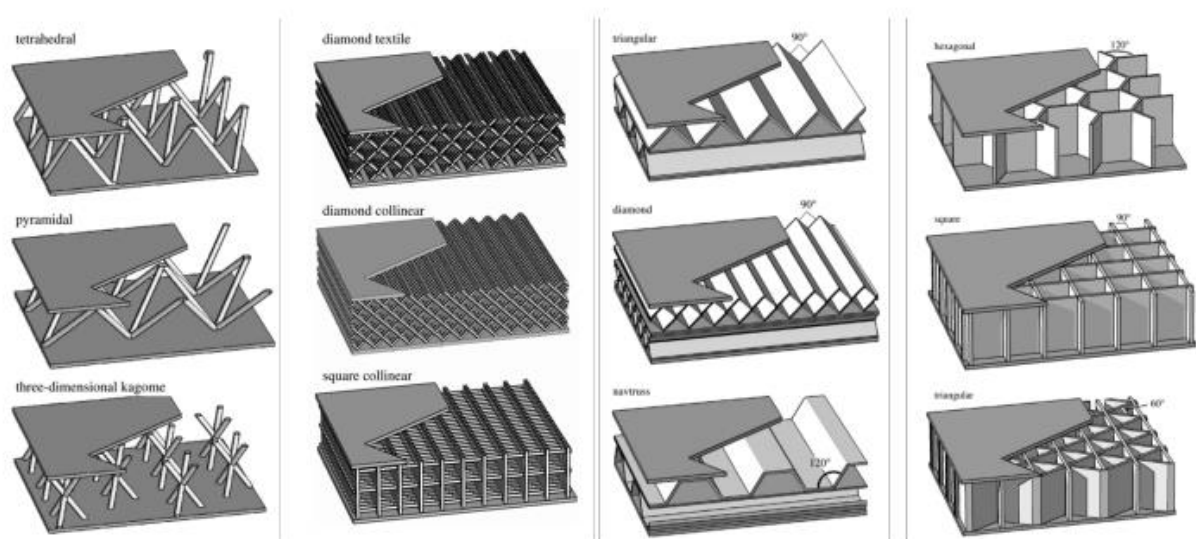


Figure 3 : Différentes formes de matériaux composites sandwich

La première utilisation connue des composites est attribuée aux Mésopotamiens. Ces peuples antiques ont collé des bandes de bois à des angles différents pour créer du contreplaqué en

3400 avant Jésus-Christ. Entre 2181 et 2055 avant J.-C., les Égyptiens ont utilisé le cartonage et des couches de lin ou de papyrus trempées dans du plâtre pour fabriquer des masques mortuaires. Vers 1500 avant J.-C., les constructeurs et artisans égyptiens et mésopotamiens utilisaient la paille pour renforcer les briques de terre, les poteries et les bateaux. Vers 25 avant J.-C., les Dix livres sur l'architecture décrivent le béton et distinguent différents types de chaux et de mortiers. Il est intéressant de noter que les recherches démontrent que le ciment décrit est similaire, et à certains égards, supérieur au ciment Portland utilisé aujourd'hui.

Ces différents exemples montrent que les matériaux composites sont utilisés depuis l'antiquité, mais c'est durant les années 30 que les composites ont commencé à avoir du succès. Reconnues comme la décennie la plus importante de l'industrie des composites, les années 1930 ont vu le développement de résines encore utilisées aujourd'hui. En 1935, l'entreprise américaine Owens Corning a introduit la première fibre de verre et a lancé l'industrie des polymères renforcés de fibres (PRF). En 1936, les résines de polyester insaturé ont été brevetées. En raison de leurs propriétés de durcissement, les résines de polyester insaturé sont le choix dominant pour les résines dans la fabrication d'aujourd'hui. En 1938, d'autres systèmes de résine plus performants, comme les époxydes, sont devenus disponibles.

Les nécessités de la Seconde Guerre mondiale ont fait passer l'industrie des PRF de la recherche à la production. En plus de leurs propriétés de haute résistance par rapport au poids, les chimistes ont appris que les composites en fibre de verre étaient transparents aux fréquences radio. Cela a conduit à l'adaptation des matériaux composites pour les dômes de radar et autres équipements électroniques. Bien qu'elles n'aient été déployées ou commercialisées qu'après la Seconde Guerre mondiale, les premières coques de bateaux de qualité commerciale ont été développées au cours de cette décennie. En 1947, une carrosserie automobile entièrement en composite a été prototypée et testée, ce qui a conduit au développement de la Corvette de 1953. Des préformes en fibre de verre imprégnées de résine et moulées dans des matrices métalliques adaptées ont été utilisées pour construire cette voiture classique. L'avènement de l'ère automobile a donné naissance à plusieurs nouvelles méthodes de moulage. Deux méthodes, le moulage par compression du composé de moulage en feuille (SMC) et le composé de moulage en vrac (BMC), sont devenues les formes dominantes de moulage pour l'industrie automobile et d'autres industries.

En 1961, la première fibre de carbone est brevetée et quelques années plus tard, elle est commercialisée. Les fibres de carbone améliorent le rapport rigidité/poids des pièces therm durcies, ce qui permet de les utiliser dans un plus grand nombre d'applications telles que l'aérospatiale, l'automobile, les articles de sport et les biens de consommation. De nos jours, la fibre de carbone est le composite le plus important de l'industrie et son importance ne fait qu'augmenter comme en atteste la Figure 4. Dans les années 1960, le marché de la marine était le plus grand consommateur de matériaux composites. C'est dans les années 70 que le marché de l'automobile dépasse le marché de la marine en tant que marché numéro un, une position qu'il conserve aujourd'hui.




Figure 4 : Demande dans l'industrie des fibres de carbonées

Au cours des vingt années suivantes, le marché des matériaux composites a progressé. Le nouveau polyéthylène de poids moléculaire très élevé a rejoint d'autres fibres de pointe utilisées dans des percées dans les composants aéronautiques, les armures structurelles et personnelles, les équipements sportifs, les appareils médicaux et d'autres applications.

Au milieu des années 1990, les matériaux composites sont devenus plus courants dans la fabrication et la construction. En tant que remplacement rentable des matériaux traditionnels comme le métal et les thermoplastiques techniques, les composites thermodurcissables étaient des composants courants dans les industries de l'électroménager, de la construction, de l'électricité et du transport.

Les marchés grand public et industriels ont vu se développer l'utilisation quotidienne des composites. Les utilisations courantes qui remontent à cette époque sont toujours d'actualité, comme en témoignent les exemples d'applications de matériaux composites suivants : poignées et boutons, infrastructures électriques, matériel de ligne de poteau, bras transversaux électriques ou encore des isolateurs.

Aujourd'hui, la recherche sur les composites attire les subventions des gouvernements, des fabricants et des universités. Ces investissements permettent d'accélérer l'innovation. Les entreprises spécialisées, telles que les entreprises de composites aéronautiques, trouveront leur place dans l'industrie. Deux applications qui continuent de connaître une croissance innovante sont les matériaux composites pour les avions et les feuilles composites pour la marine.

D'autres matériaux tels que les résines écologiques incorporant des plastiques recyclés et les polymères biosourcés répondent à la demande de produits plus solides, plus légers et respectueux de l'environnement. À l'avenir, les fibres et les résines encore à développer créeront encore plus d'applications pour un usage quotidien et spécialisé.

2) Etat de santé des structures

L'état de santé des structures (SHM, Structural health monitoring) est une approche pluridisciplinaire qui regroupe l'ensemble des méthodes, techniques, technologies et disciplines qui ont pour objectif d'évaluer l'intégrité, la santé et le maintien dans le temps des structures afin de détecter et prédire leurs défaillances et donc prolonger leur durée de vie.

Cela peut donc mettre en œuvre des compétences en matériaux, en contrôles non destructifs (CND), des capteurs, de l'instrumentation, l'architecture de systèmes, la maintenance mais également de l'analyse de données et de la modélisation. A cela il faut ajouter la stratégie de surveillance mis en place pour la structure concernée.




Figure 5 : Les différents rôles du SHM

Le SHM est utilisé pour surveiller ou suivre le comportement d'une structure, ainsi que son évolution dans son ensemble. Mais les objectifs recherchés peuvent être différents comme nous pouvons le voir sur le graphique de la figure 5, cela peut viser à éviter le démantèlement d'une structure, détecter un endommagement, garantir la fiabilité des structures, réduire le travail des équipes de maintenance, etc. De plus, on remarquera les différents types d'endommagement visés à être détectés par les SHM sur la figure 6, par exemple les fissures, la corrosion, le délaminage et la dégradation thermique.




Figure 6 : Les types dommages visés des SHM

Maintenant, intéressons-nous aux différentes méthodes non-destructives (figure 7). En ingénierie civile, les méthodes varient selon l'application. Avec l'évolution et le développement de la technologie des capteurs et des techniques de traitement du signal, différents types de capteurs sont utilisés dans les systèmes SHM. L'une des applications les plus réussies de la SHM concerne les machines tournantes et repose sur la reconnaissance des caractéristiques

des vibrations structurales, telles que le déplacement, la vitesse et l'accélération (voir figure 8). Cependant, au début, ce type de SHM était également basée sur l'inspection visuelle des signaux dans les domaines temporel ou fréquentiel, en comparant les caractéristiques du signal actuel avec les caractéristiques extraites de la mémoire dans des conditions de fonctionnement sans dommage. Cette approche était encore qualitative. Plus récemment, avec le développement rapide de l'informatique, la reconnaissance des formes est devenue un domaine de recherche populaire. La SHM basée sur la reconnaissance des formes est devenue un domaine de recherche populaire. Grâce à l'amélioration significative des capacités des ordinateurs en matière de traitement de l'information, l'efficacité et la précision de la gestion des stocks et de la maintenance ont été grandement améliorées.

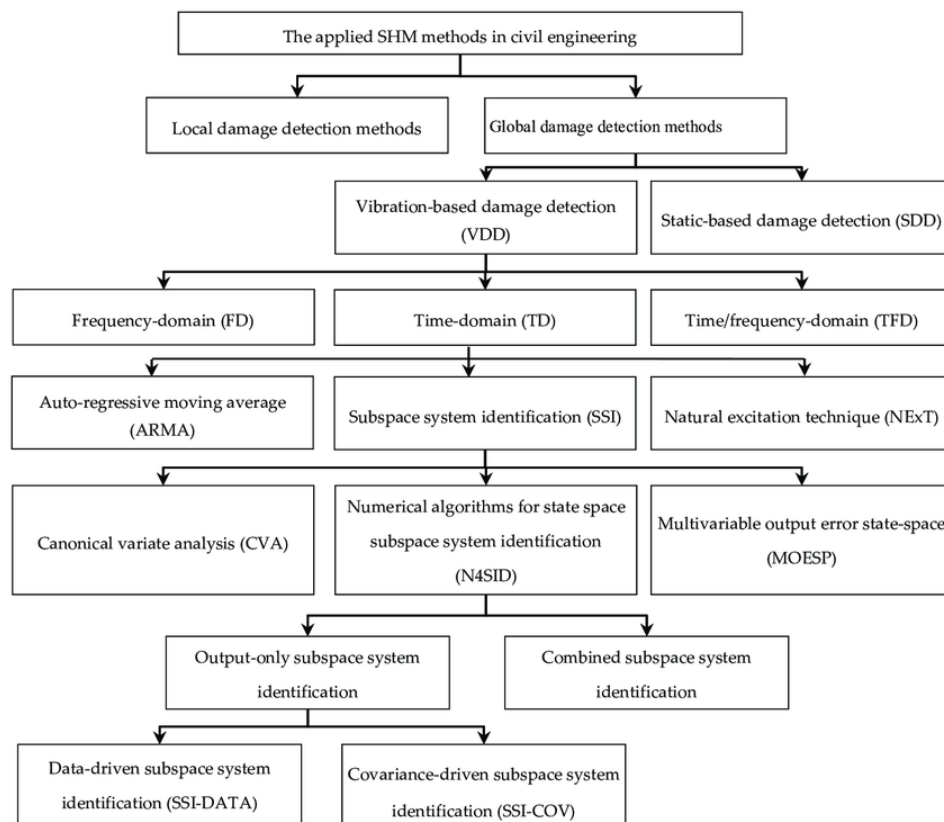


Figure 7 : Les différentes méthodes de SHM en génie civil




Figure 8 : Machines tournantes : 1. servo-moteur ; 2. couple ; 3. roulement ; 4. palier ; 5. disque ; 6. arbre ; 7. accéléromètre 8. plaque métallique

3) L'intelligence artificielle

L'intelligence artificielle est l'ensemble des techniques utilisées sous forme d'algorithmes pour simuler l'intelligence humaine comme pour l'apprentissage ou le raisonnement. Comme vous pouvez le voir dans la figure 9, l'intelligence artificielle est composée de deux grandes parties : Le machine learning et le deep learning (qui est une partie du machine learning).

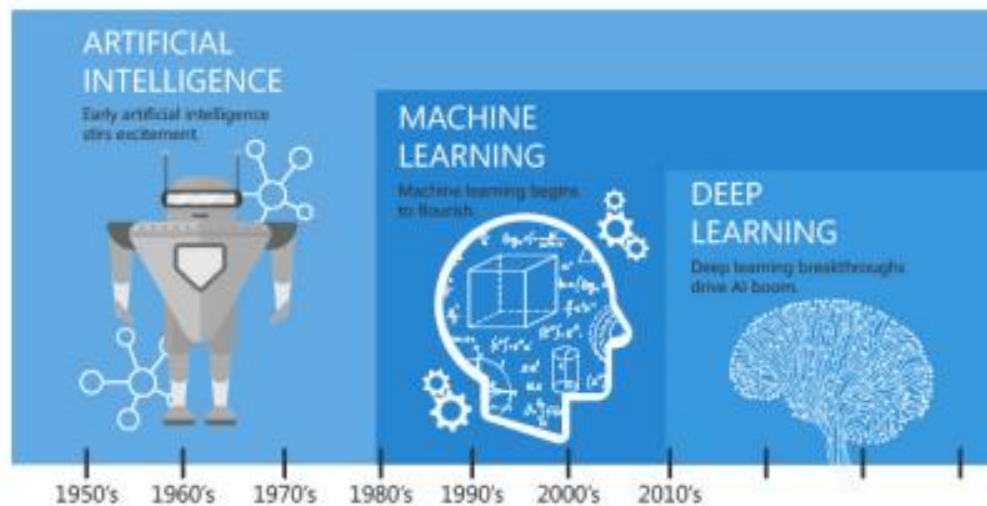


Figure 9 : Les différentes parties de l'intelligence artificielle

a) Le machine learning

Le machine learning est composé de plusieurs catégories qui sont associées à différentes applications que nous pouvons voir dans la figure 10. L'apprentissage supervisé nécessite une entrée connue et une sortie connue. L'apprentissage non supervisé, contrairement aux méthodes précédentes, est utilisé pour tirer des modèles des données d'entrée sans référence à des résultats étiquetés. Les principales méthodes sont la réduction de la dimension et le clustering (regroupement).

La régression linéaire, qui est une méthode d'apprentissage supervisée, tente de trouver une ligne qui représente la relation entre une sortie et une ou plusieurs sorties :

$$Y = aX + b + \varepsilon \text{ où } f(X) = aX + b$$

Nous calculons ensuite le coefficient de corrélation pour évaluer dans quelle mesure la ligne est proche du modèle réel :

$$R = \frac{\sum_{i=1}^p (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^p (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^p (Y_i - \bar{Y})^2}}$$

Nous essayons de minimiser l'erreur entre la fonction et le modèle réel :

$$\varepsilon = \sum_{i=0}^P (Y_i - (aX_i + b))^2$$

Supervised learning	Unsupervised learning	Semi-supervised learning	Reinforcement learning
<p>Data scientists provide input, output and feedback to build model (as the definition)</p> <p>EXAMPLE ALGORITHMS:</p> <p>Linear regressions</p> <ul style="list-style-type: none"> ■ sales forecasting ■ risk assessment <p>Support vector machines</p> <ul style="list-style-type: none"> ■ image classification ■ financial performance comparison <p>Decision tree</p> <ul style="list-style-type: none"> ■ predictive analytics ■ pricing 	<p>Use deep learning to arrive at conclusions and patterns through unlabeled training data.</p> <p>EXAMPLE ALGORITHMS:</p> <p>Apriori</p> <ul style="list-style-type: none"> ■ sales functions ■ word associations ■ searcher <p>K-means clustering</p> <ul style="list-style-type: none"> ■ performance monitoring ■ searcher intent 	<p>Builds a model through a mix of labeled and unlabeled data, a set of categories, suggestions and exemplar labels.</p> <p>EXAMPLE ALGORITHMS:</p> <p>Generative adversarial networks</p> <ul style="list-style-type: none"> ■ audio and video manipulation ■ data creation <p>Self-trained Naïve Bayes classifier</p> <ul style="list-style-type: none"> ■ natural language processing 	<p>Self-interpreting but based on a system of rewards and punishments learned through trial and error, seeking maximum reward.</p> <p>EXAMPLE ALGORITHMS:</p> <p>Q-learning</p> <ul style="list-style-type: none"> ■ policy creation ■ consumption reduction <p>Model-based value estimation</p> <ul style="list-style-type: none"> ■ linear tasks ■ estimating parameters

Figure 10 : Les différentes méthodes de Machine Learning

Le K-means clustering est une méthode qui sélectionne K points aléatoires dans nos ensembles de données. Elle calcule ensuite la distance entre chaque point et les K points. Comme son nom l'indique, nous utilisons la méthode de la moyenne pour calculer les distances :

$$|x_1 - x_{K1}| + |x_2 - x_{K1}| + \dots + |x_n - x_{Kn}| = \text{Distance d'un point jusqu'à un K point}$$

Ensuite, nous assignons chaque point au cluster le plus proche de lui. Ensuite, pour chaque cluster, nous recalculons le point moyen :

$$\begin{matrix} x(\text{point moyen du cluster } i) \\ y(\text{point moyen du cluster } i) \end{matrix} = \frac{1}{n} * \begin{matrix} \sum_{k=0}^n x_k \\ \sum_{k=0}^n y_k \end{matrix}$$

Nous répétons les 2 opérations précédentes jusqu'à ce que les points moyens des clusters finaux ne changent plus.

Cette méthode permet non seulement d'identifier les différents groupes entre les points mais aussi de générer les valeurs moyennes pour chacun de ces groupes (figure 11). Elle crée une sous-donnée composée uniquement des points moyens qui peut également être exploitée par des modèles d'apprentissage automatique. Le K means cluster nous permet, en créant des clusters, d'identifier des classes et des sous-classes à condition d'avoir plus de 2 clusters tout en représentant chaque relation entre eux.

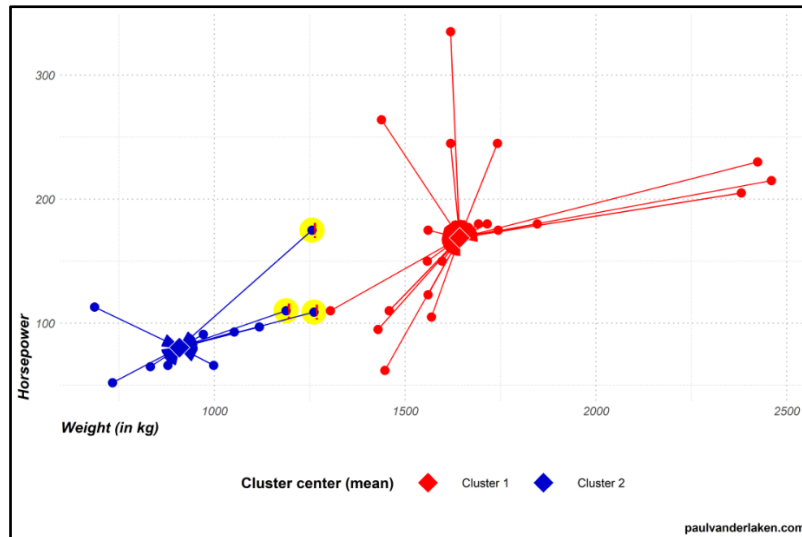


Figure 11 : Résultats d'un algorithme k-means

L'apprentissage par arbre de décision est l'une des approches de modélisation prédictive utilisée en statistiques, l'exploration de données et l'apprentissage automatique. Un arbre de décision est un modèle qui imite un arbre avec des racines, des branches et des feuilles, mais il est dessiné à l'envers, avec sa racine au sommet. Les arbres décisionnels sont de deux types principaux : l'arbre de classification et l'arbre de régression. L'arbre de classification est utilisé lorsque la variable cible est un ensemble de valeurs discrètes, tandis que l'arbre de régression est utilisé lorsque la cible prend des valeurs continues. Dans les deux modèles, la racine représente les données d'entrée, les branches représentent les différentes caractéristiques et les feuilles représentent les étiquettes de classe pour la classification ou les valeurs continues pour la régression. Les modèles d'arbre de décision sont faciles à comprendre et à interpréter, mais ils peuvent être très peu robustes parce qu'un petit changement dans les données de formation peut entraîner une grande différence dans les prédictions. Un exemple simple d'arbre de décision dans le domaine des maladies cardiovasculaires est illustré à la figure 12. Il s'agit d'un arbre de classification.

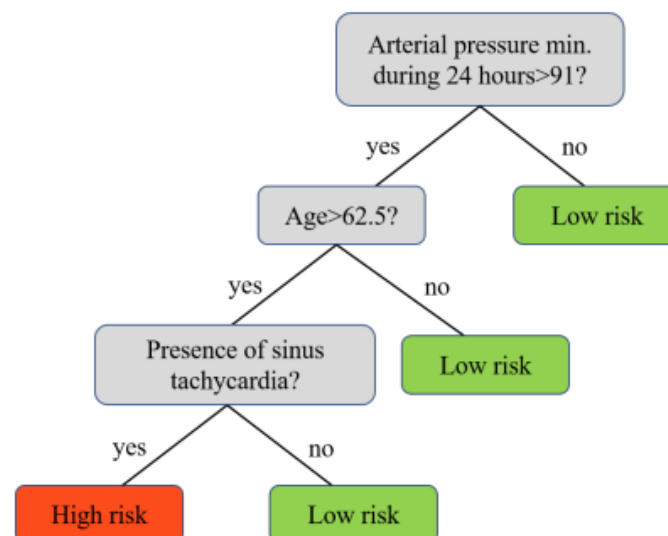


Figure 12 : Arbre de probabilité dans le domaine des maladies cardiovasculaires

b) Le deep learning

Domaine le plus en vue du machine learning, le deep learning a fait l'objet d'une attention croissante ces dernières années. Le deep learning a montré un grand potentiel dans de nombreux domaines, notamment la biologie, la médecine, l'architecture, les transports, la défense, etc. Voici deux exemples de deep learning couramment utilisés seront brièvement présentés.

Les auto-encodeurs (AE) sont des réseaux neuronaux qui visent à compresser et à encoder efficacement des données dans une représentation de l'espace latent, puis à reconstruire la sortie à partir de cette représentation. L'objectif est de rendre la sortie aussi proche que possible du signal original (l'entrée). Il s'agit d'un réseau neuronal non supervisé. L'AE se compose de deux parties principales :

- L'encodeur, dans lequel le modèle apprend à réduire les dimensions des données d'entrée et à les compresser dans une représentation en espace latent.
- Le décodeur, dans lequel le modèle apprend à récupérer les données d'entrée aussi précisément que possible à partir de la représentation codée.

Dans les applications, l'AE peut réduire de façon exponentielle le coût de calcul en réduisant les dimensions des données. Mais il apprend à capturer le plus d'informations que possible plutôt que le maximum d'informations pertinentes. Il peut ne pas être capable de déterminer quelles informations sont pertinentes. Dans les applications, l'EA peut également être utilisée à des fins de réduction du bruit en raison de sa capacité à réduire les dimensions des données. Le bruit dans les données peut être ignoré par apprentissage. Un exemple de débruitage d'image à l'aide de AE est illustré à la figure 13. L'image d'entrée/sortie provient de l'ensemble de données MNIST.


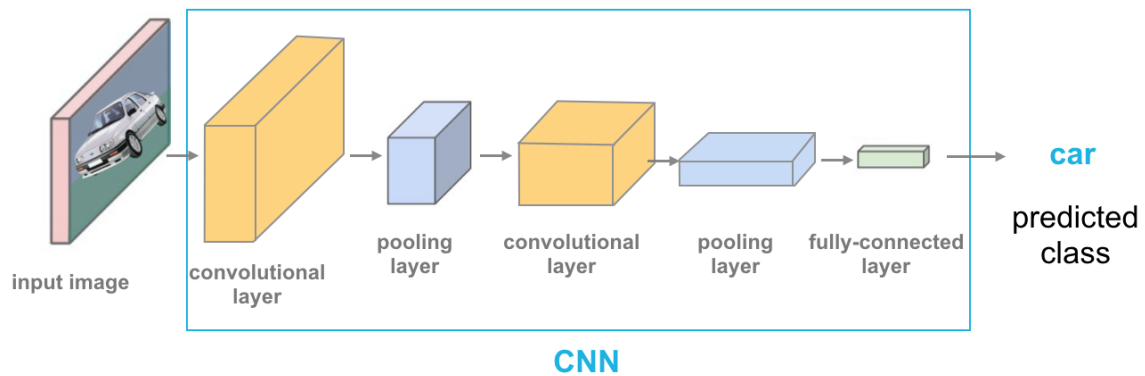


Figure 13 : Architecture d'un auto-encodeur

Le réseau neuronal convolutif (CNN) est un type de réseau neuronal de deep learning. Il est similaire aux réseaux neuronaux ordinaires composés de neurones qui ont des poids et des biais réglables. La différence est que dans un réseau neuronal ordinaire, chaque neurone de chaque couche est entièrement connecté à tous les neurones de la couche voisine, ce qui rend le réseau susceptible de surentrainer les données, tandis que dans le réseau CNN, des

filtres sont utilisés entre les couches et, pour chaque couche, chaque sortie n'est liée qu'à une partie de l'entrée, au lieu de prendre en compte toutes les entrées. Dans le CNN, il y a trois couches principales en plus de la couche d'entrée et de la couche de sortie, à savoir la couche convolutive, couche de mise en commun (pooling layer) et couche entièrement connectée (fully-connected layer). Cette technique de deep learning est très efficace sur les bases de données importantes qui contiennent des images.



14 : Architecture d'un Réseau Neuronal Convolutif (CNN)

II - ETABLIR UNE BASE DE DONNÉES

1) Les matériaux Composites

Un matériau composite est un assemblage d'au moins deux matériaux. Un matériau joue le rôle de matrice et l'autre celui de renfort. La matrice est une protection du renfort et permet d'obtenir une cohésion de l'assemblage et de transmettre les efforts mécaniques au renfort. Le renfort est l'ossature qui assure la tenue mécanique du matériau composite et peut prendre différentes formes en fonction de l'application recherchée. Il existe 3 majeures familles de matériau composites qui dépendent de la nature de la matrice.

Les composites à matrices organiques (CMO) qui constituent, de loin, les volumes les plus importants aujourd'hui à l'échelle industrielle. Les résines époxy sont des matrices utilisées avec les fibres de carbone pour la réalisation de pièces de structure et d'aéronautique.

Le CMC (ou composite à matrice céramique) qui est majoritairement utilisé pour des domaines très spécifiques à haute technicité et à température élevée : spatial, militaire ou encore nucléaire.

Les composites à matrices céramiques (CMC) réservés aux applications de très haute technicité et travaillant à haute température comme le spatial, le nucléaire et le militaire, ainsi que le freinage (freins carbone).




Figure 15 : Matériau Composite et sa constitution

On dit qu'un matériau composite est fait d'éléments non miscibles. Cela s'explique par le fait qu'on cherche à créer un produit supérieur en combinant une multitude de matériaux qui gardent leurs propriétés d'origine. On crée ainsi un nouveau matériau complexe et constitué en couches possédant des propriétés nouvelles que les éléments n'ont distinctement pas.

On aboutit à des améliorations tantôt sur la rigidité, sur la solidité, sur la flexibilité et bien d'autres applications. En effet, puisque la création d'un matériau composite réside dans la liberté du choix de ses composants, il existe, en théorie, une infinie possibilité de matériaux.

composite, chacun avec ses propres propriétés. Nous sommes donc dans la capacité de créer des matériaux composites « à la carte » avec des propriétés idéalement conçues pour une application bien précise.

Un autre atout de taille du matériau composite est sa masse volumique. C'est pour cela qu'elle excelle dans les domaines du transport, que cela soit terrestre, maritime, aérien, ferroviaire ou spatiaux.

Caractéristiques	Métaux			Composites à matrices organiques ⁽¹⁾			
	Acier 35 NCD 16	Alliage aluminium AU 4 SG	Alliage Titane TA 6 V	Carbone HR / résine époxyde	Carbone HM / résiné époxyde	Aramide / résine époxyde	Verre R / résine époxyde
Caractéristiques en traction :							
Résistance à la rupture R (MPa)	1850	500	1000	1000 à 1300	1000	1300 à 1800	1800 à 2000
Module d'Young E (GPa)	200	72	110	130	200	75	53
Masse volumique ρ (g/cm ³)	7.9	2.8	4.45	1.5	1.7	1.37	2
Résistance à la rupture massique R/ρ (km)	24	18	23	65 à 85	60	95 à 130	90 à 100
Module d'Young massique E/ρ (km)	2500	2600	2500	8700	11800	5500	2650
Coefficient de dilatation linéique (K ⁻¹) :							
longitudinal	12 – 10 ⁻⁶	23 – 10 ⁻⁶	(2)	-0.2 – 10 ⁻⁶	-0.8 – 10 ⁻⁶	-5 – 10 ⁻⁶	6 – 10 ⁻⁶
transversal	12 – 10 ⁻⁶	23 – 10 ⁻⁶	(2)	35 – 10 ⁻⁶	35 – 10 ⁻⁶	60 – 10 ⁻⁶	31 – 10 ⁻⁶

Figure 16 : Comparaison de caractéristiques de matériaux composites et de métaux

Dans le tableau ci-dessus nous pouvons observer différentes caractéristiques de matériaux de métaux simples face à des matériau composite. Le module de Young est la contrainte mécanique qui engendrerait un allongement de 100 % de la longueur initiale d'un matériau. La rigidité ou la souplesse de définit par cette valeur du module d'Young, plus elle est élevée, plus le matériau est rigide. Le coefficient de dilation linéique est une caractéristique d'un matériau exprimant sa capacité de dilatation ou de rétraction selon une direction axiale, exprimé en K-1. Il correspond à sa variation relative de longueur sous l'effet d'une variation de température d'un kelvin. Un plus grand coefficient indique une modification du matériau (en général de sa longueur) et donc une sensibilité à des changements de températures.

2) Notre matériau composite

Pour pouvoir étudier correctement l'étendue des capacités d'un matériau composite mais également sa capacité à réagir à une force, nous décidons de commencer par étudier une double couche de solide. La base sera en acier et la 1ere couche en aluminium. Nous choisissons 2 plaques de 1 mètre sur 20 centimètres et d'une épaisseur respective de 15 millimètres et 10 millimètres.




Figure 17 : Matériau composite choisi pour notre étude

Nous choisissons un modèle simple pour comprendre l'interaction de deux matériaux distincts face à l'exertion d'une force. Il n'est donc pas nécessaire d'identifier la matrice et le renfort ou de choisir des matériaux propices à la création d'un matériau composite utile et efficace. De plus, la finalité de notre projet est de créer une intelligence artificielle capable de reconnaître la présence d'un crack dans un matériau composite. Cela se traduit par une déformation de sa structure face à une force. L'entraînement de cette IA peut donc s'effectuer sur un matériau quelconque présentant des défauts dans sa structure.

3) La construction de l'expérience

On positionne notre 1^{er} solide par rapport à l'origine et le 2^{ème} en prenant en compte le décalage du 1^{er} solide.

Solid ID List	Solid ID List
1	2
Refer. Coordinate Frame Coord 0	Refer. Coordinate Frame Coord 0
Vector Coordinates List <1 0,2 0.015>	Vector Coordinates List <1 0,2 0.010>
<input checked="" type="checkbox"/> Auto Execute	<input checked="" type="checkbox"/> Auto Execute
Origin Coordinates List [0 0 0]	Origin Coordinates List [0 0 0.015]

Figure 18 : Création des solides 1 et 2 selon les dimensions associées

La prochaine étape est d'enregistrer les propriétés physiques des matériaux que nous allons exploiter. Ici, nous utiliserons de l'acier de l'aluminium. Il faut ensuite associer chaque solide avec un matériau ainsi créé.

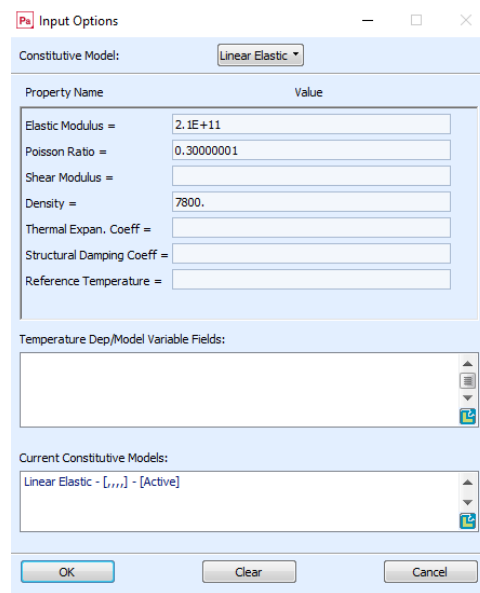


Figure 19 : Propriétés Acier

Ici survient l'ensemble d'étapes qui va nous permettre de créer notre base de données. Il s'agit du maillage de notre structure. Pour effectuer nos calculs de structure, le maillage est indispensable puisque nous discrétisons notre matériau en éléments finis. Cela signifie que nous découpons la structure en éléments de forme géométriques, ici des rectangles 3D, dont le potentiel de déformation est déterminé.

Nous prenons 20 mailles en longueur, 5 en largeur et 10 en hauteur.




Figure 20 : Création des nœuds de mailles sur les surfaces de la structure




Figure 21 : Création des nœuds de mailles sur les arrêtes de la structure

Nous procédons ensuite à « la découpe » de notre structure. Il ne s'agit pas en réalité d'une réelle découpe mais de la définition de chaque élément comme une maille.




Figure 22 : Maillage selon les nœuds précédemment définis

4) Les cracks

Pour avoir une base de données exploitable, nous décidons de simuler différents types de crack. Ce que l'on appelle crack sur Patran est représenté par une suppression des nœuds créés par le maillage. Cela se traduit par une perte de contact, ou de fusion, entre les deux solides ce qui reproduit un phénomène de décollement, à savoir que cette partie des couches ne sont plus liées mais repose l'une sur l'autre. Cela va permettre, lors de l'exertion d'une force, de faire réagir indépendamment, toujours uniquement sur la partie où l'on a supprimé les nœuds de maillage, les solides. Pour réaliser correctement cette expérience, nous devons d'encastrer deux faces d'un solide pour pouvoir réagir à une force normale et ne pas être en état de chute libre.




Figure 23 : Création de l'encastrement sur une surface de la structure

Maintenant que nous avons la définition d'un crack, nous pouvons définir quels types de crack sont intéressants à exploiter. Nous décidons de simuler deux différents types de crack. Le 1^{er} sera un crack à l'extrémité, celle non-encastree, dont nous ferons varier la longueur pour étoffer notre base de données. La fissure se fera toujours au niveau de la jointure entre les deux solides et sur la largeur du solide.




Figure 24 : Cassure de type H : A l'extrémité de la surface

Le deuxième crack intéressant à exploiter est un crack qui se situe au milieu, ou à l'intérieur, de la structure. En effet, un défaut dans le matériau est souvent interne et pas aux extrémités. Le comportement face à une force normale sera donc différent et utile à exploiter. Le principe de fissure est le même puisqu'il s'agit d'une exclusion d'une ou plusieurs rangées de nœuds, toujours sur la longueur de la structure, mais qui prends ici son origine à l'intérieur du solide et non plus à l'extrémité.




Figure 25 : Cassure de type T : Au milieu de la structure

5) Les modes et fréquences

La simulation se fera à l'aide des modes normaux de la structure. La déformée que l'on pourra observer est associée à un mode et une fréquence. Un mode normal ou propre est donc la forme que va adopter le matériau face à une perturbation ou l'application d'une force. Pour notre expérience, nous décidons d'étudier les 10 premiers modes auxquels sont associés une déformée et une fréquence. Cela nous permettra d'entraîner une intelligence artificielle capable de reconnaître l'état d'un matériau en fonction de ses modes normaux.

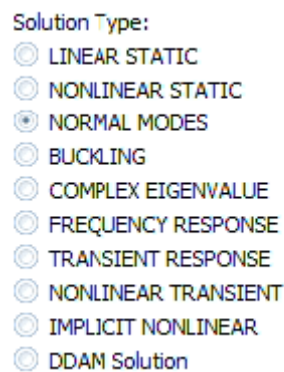


Figure 26 : Sélection du type de solution à exploiter.

La fréquence associée à chaque mode sera stockée dans un fichier Excel et pourra servir pour implémenter une deuxième intelligence artificielle en utilisant des outils de Machine Learning. Cela permettra d'avoir deux dimensions d'exploitation de notre simulation pour mieux analyser les résultats.

```

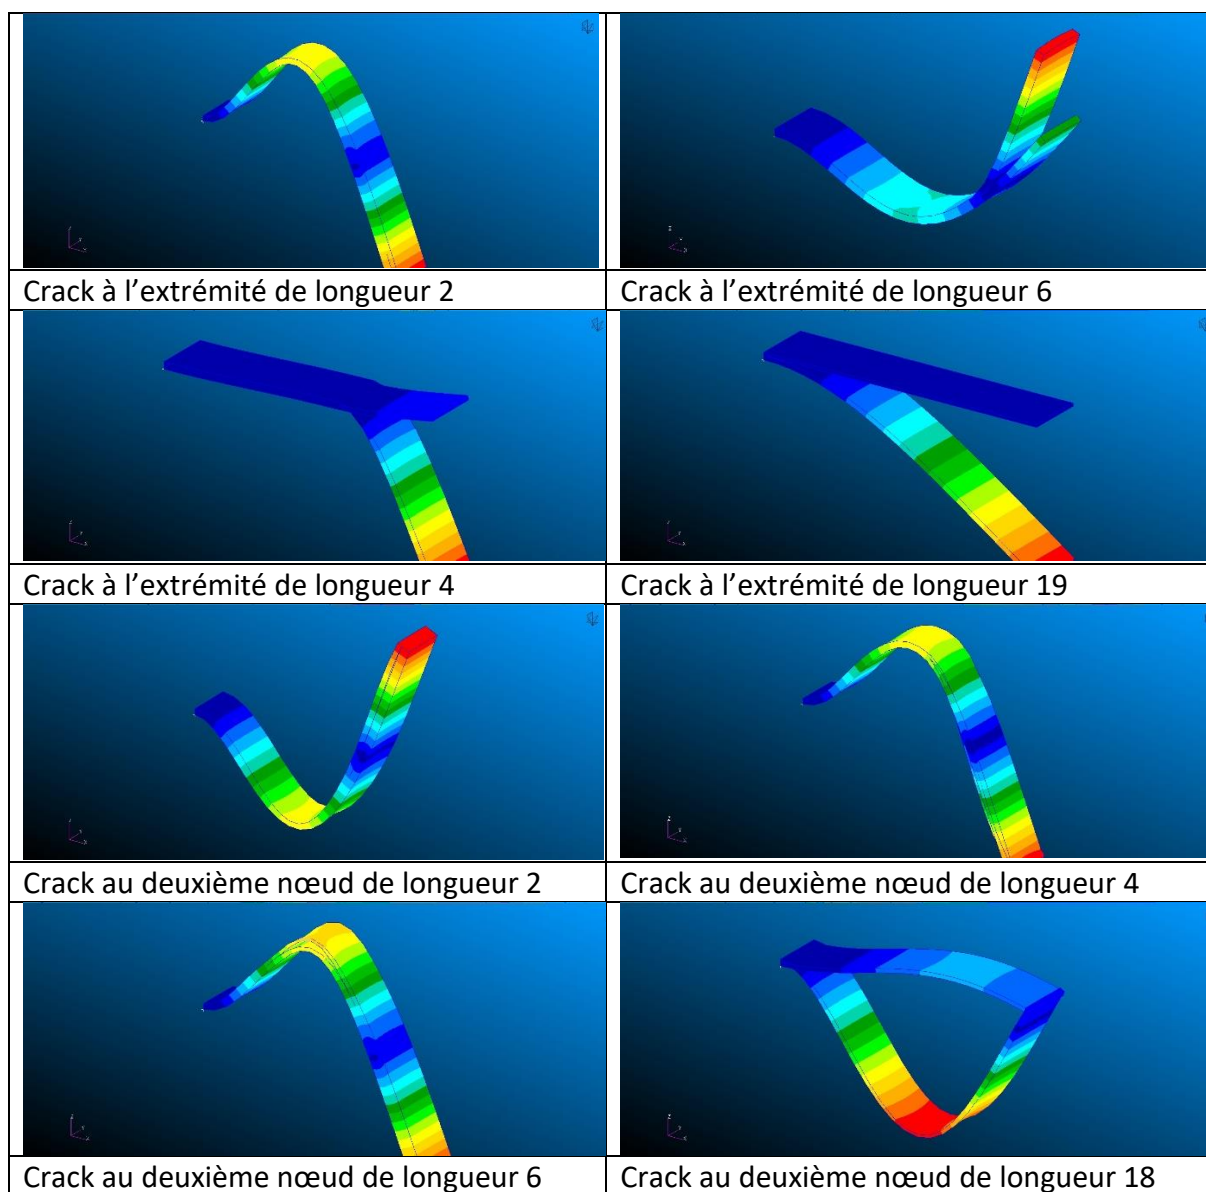
Select Result Cases
DEFAULT, A1:Mode 1: Freq. =18.6525
DEFAULT, A1:Mode 2: Freq. =116.532
DEFAULT, A1:Mode 3: Freq. =163.282
DEFAULT, A1:Mode 4: Freq. =172.935
DEFAULT, A1:Mode 5: Freq. =326.532
DEFAULT, A1:Mode 6: Freq. =525.852
DEFAULT, A1:Mode 7: Freq. =641.222
DEFAULT, A1:Mode 8: Freq. =880.411

```

Figure 27 : Sélection du mode à visualiser

6) Les résultats

Comme dit précédemment, à chaque mode est associé une déformée. Ainsi nous pouvons observer l'impact qu'a eu la fissure sur notre structure. Ci-dessous nous pouvons observer les 2èmes modes de cette même structure avec des cracks différents.



En observant ces résultats, nous pouvons y associer une frange de couleurs qui indique l'importance de l'effort subi. C'est un paramètre de plus pour comprendre l'influence d'un crack sur notre matériau. Ci-dessous est le second mode du matériau sans crack. On peut observer rapidement la différence des franges de couleurs en fonction du crack.




Figure 28 : Mode 2 d'un modèle sain de notre matériau

Cependant, cela n'est pas évident dans certains cas où le crack n'est pas de taille importante. On pourra alors s'appuyer sur la nette différence des formes pour en tirer des conclusions plus concrètes. Il est donc nécessaire d'avoir comme résultats exploitables les modes, les fréquences, la forme ainsi que les couleurs.

7) La base de données

Pour exploiter au mieux ces images, nous supprimons un maximum d'information, de légende ou bien de labels présents sur notre image. Nous décidons ensuite de bien centrer les images avec l'outil automatique du logiciel Patran. Il arrive que cela coupe une partie de notre matériau ce qui pose un problème. Cependant, cela est négligeable face à la nécessité de créer une base de données exploitable avec des images de dimensions identiques pour notre IA.

Lors de la simulation, une multitude de fichiers sont créés. Nous pouvons récupérer les fréquences associées à chaque mode dans un de ceux-ci que nous extrayons à la main. Nous les rentrons ensuite dans un fichier Excel en l'associant, à l'aide de mots-clés, à la simulation auquel il correspond.

MODE NO.	EXTRACTION ORDER	EIGENVALUE	R E A L E I G E N V A L U E S		GENERALIZED MASS	GENERALIZED STIFFNESS
			RADIANS	CYCLES		
1	1	1.373520E+04	1.171973E+02	1.865252E+01	1.000000E+00	1.373520E+04
2	2	5.361540E+05	7.322254E+02	1.165373E+02	1.000000E+00	5.361540E+05
3	3	1.052540E+06	1.025934E+03	1.632824E+02	1.000000E+00	1.052540E+06
4	4	1.181631E+06	1.087028E+03	1.730060E+02	1.000000E+00	1.181631E+06
5	5	4.212099E+06	2.052340E+03	3.266400E+02	1.000000E+00	4.212099E+06
6	6	1.099891E+07	3.316461E+03	5.278311E+02	1.000000E+00	1.099891E+07
7	7	1.627156E+07	4.033803E+03	6.419996E+02	1.000000E+00	1.627156E+07
8	8	3.060067E+07	5.531787E+03	8.804113E+02	1.000000E+00	3.060067E+07
9	9	3.256234E+07	5.706342E+03	9.081926E+02	1.000000E+00	3.256234E+07
10	10	4.478329E+07	6.692032E+03	1.065070E+03	1.000000E+00	4.478329E+07
1 MSC.NASTRAN JOB CREATED ON 22-JAN-22 AT 11:00:01 JANUARY 24, 2022 MSC Nastran 6/10/21 PAGE 88						
0						SUBCASE 1

Figure 29 : Extraction des fréquences dans le fichier texte des résultats

h_4	h_6	T_2_2	T_2_3	T_2_4	T_2_6	T_10_2
1.862064E+0	1.849686E+0	1.865200E+0	1.863831E+0	1.861711E+0	1.851892E+0	1.860447E+0
1.112507E+0	7.059386E+0	1.164564E+0	1.147952E+0	1.129807E+0	1.082371E+0	1.164332E+0
1.403720E+0	1.063334E+0	1.632824E+0	1.632815E+0	1.632800E+0	1.632517E+0	1.632688E+0
1.632801E+0	1.631528E+0	1.729224E+0	1.715887E+0	1.700421E+0	1.647732E+0	1.663452E+0
1.696095E+0	1.636023E+0	3.255771E+0	3.104161E+0	3.021982E+0	2.566626E+0	3.109359E+0
2.915559E+0	2.608703E+0	5.255990E+0	4.947100E+0	4.696454E+0	3.045532E+0	5.092627E+0
3.763506E+0	2.682349E+0	6.379499E+0	5.990151E+0	4.698125E+0	4.250944E+0	6.374436E+0
4.839655E+0	4.334831E+0	8.804110E+0	6.902780E+0	6.094100E+0	5.019723E+0	8.530739E+0
5.563073E+0	4.365551E+0	8.982255E+0	8.097121E+0	7.202814E+0	5.683042E+0	8.804034E+0
7.907908E+0	5.678003E+0	1.058014E+0	8.804104E+0	8.058595E+0	7.646935E+0	9.565424E+0

Figure 30 : Création du fichier Excel avec les valeurs numériques des fréquences

8) Pour aller plus loin

Ici, nous avons fait le choix de ne travailler qu'avec deux solides posés l'un sur l'autre. Pour étudier un matériau composite, une structure en « sandwich » était plus judicieux. De plus, pour la simulation, séparer un solide en 2 verticalement, c'est-à-dire créer 2 solides fait d'un même matériau au lieu d'un seul solide, aurait pu nous permettre d'étudier des cracks verticaux et pas seulement horizontaux. Nous avons simplifié l'expérience pour entraîner une intelligence artificielle capable de reconnaître s'il y a un problème ou non, sans forcément être capable d'identifier quel type de problème existe. C'est la raison pour laquelle une structure complexe n'était pas nécessaire pour notre étude.

III – L'INTELLIGENCE ARTIFICIELLE

L'intelligence artificielle (IA) que l'on souhaite réaliser doit résoudre deux problèmes distincts. Dans un premier temps, l'IA devra prédire si le matériau présenté en entrée est sain ou non (P_1). Dans un second temps, elle devra prédire le type de cassure du matériau présenté c'est-à-dire sain si aucune cassure, cassure de type H ou cassure de type T (P_2).

1) Le choix de l'architecture

Avant de commencer à programmer une IA, il faut d'abord savoir quelles architectures d'IA vont être testées. Il en existe tant que l'on pourrait perdre la tête : réseau de neurones, arbre de décision, bayésien naïf, régression linéaire, machine à vecteur de support, auto-encodeur, ... Et il faut considérer en plus de ceux cités (liste non exhaustive) leurs propres variations. On en arrive à même pouvoir créer des zoos comme celui destiné aux différents types de réseaux de neurones¹. Ainsi, cette phase préliminaire de brainstorming est nécessaire afin d'éviter les architectures qui ne sont pas viables de base, si de telles architectures existent, ou de tout simplement s'éparpiller un peu trop.

Avec un problème tel que détecter une cassure dans un matériau composite, on s'attend à avoir des images en entrée plutôt qu'un vecteur de donnée classique comportant un ensemble de valeurs numériques ou non. Dans un cas comme celui-ci, ce sont des architectures de type réseau de neurones de convolution (CNN) qui viennent en premier en tête : elles sont considérées aujourd'hui comme les meilleures dès que des images sont impliquées. On peut par exemple citer YOLO (You Only Look Once) ou U-Net, deux architectures bien connues dans le monde du traitement d'images respectivement pour les problèmes de détection d'objets (position et nature de l'objet) et de segmentation d'image.


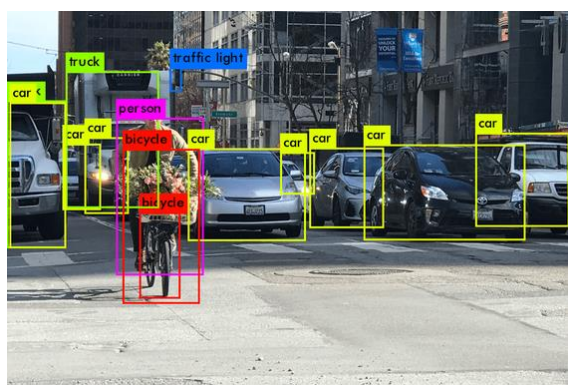


Figure 31 : Sortie de YOLO (à gauche) et architecture U-Net (à droite)

Le seul problème avec un CNN est que cela est du Deep Learning, qui nécessite une base de données gigantesque pour l'apprentissage. Cependant, notre base de données ne comporte que 170 éléments. On peut donc écarter cette possibilité en allant plutôt aller chercher du côté des architectures liées au Machine Learning. En effet, ce sont des architectures qui apprennent à résoudre un problème donné avec une bonne précision en utilisant des bases de données plus petites.

¹ <https://www.asimovinstitute.org/neural-network-zoo/>

Une première proposition à tester est le perceptron. C'est la forme la plus simple de réseau de neurones. Cette simplicité forme son plus grand avantage : être peu gourmand en puissance de calcul. Cependant, cette simplicité fait qu'il peut rapidement atteindre ses limites et ne pas donner une bonne précision de prédictions selon le problème.




Figure 32 : Perceptron à 2 entrées et 1 sortie

Une seconde proposition est l'arbre de décision. C'est un algorithme différent du réseau de neurones mais il reste simple à comprendre et mettre en place. Son seul problème réside dans l'instabilité de la forme de l'arbre : on n'aura pas forcément le même arbre à la suite de deux entraînements identiques.

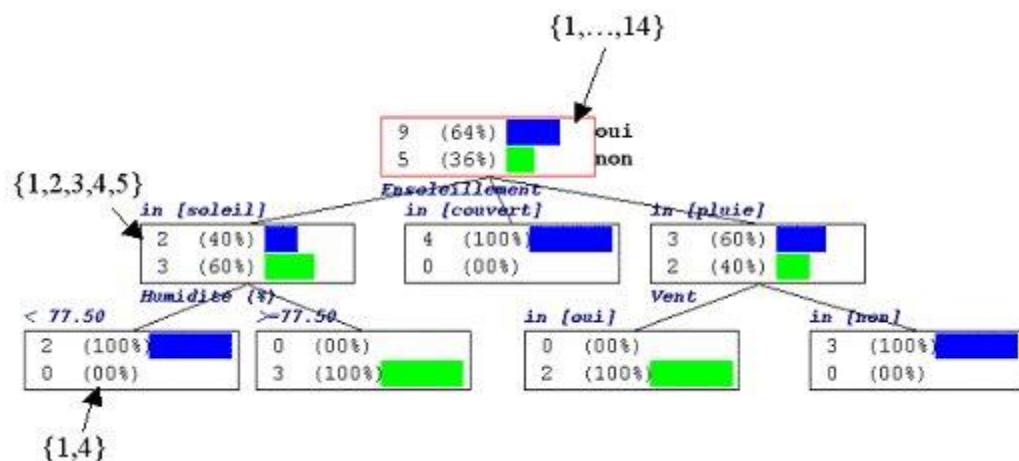


Figure 33 : Exemple d'arbre de décision

Le tableau ci-dessous résume les points forts et les faibles des architectures envisagées pour résoudre notre problème.

Nom	Avantages	Inconvénients
CNN	Très efficace pour traiter des images	Beaucoup de données pour l'entraînement
Arbre de décision	Plus simple qu'un Réseau de Neurones	Instabilité dans la structure de l'arbre
Perceptron	Très simple et léger	Peut rapidement atteindre ses limites selon l'application

2) Perceptron

Un perceptron est un réseau de neurones sans couches cachées : la sortie est directement fonction de l'entrée sans passer par des intermédiaires.

Cette sortie, que l'on va appeler Y_{pred} , se calcul à partir de l'entrée X sous forme de vecteur à n dimensions comme suit :

$$Y_{pred} = \sigma \left(b + \sum_{i=1}^n W_i X_i \right)$$

On remarque déjà qu'il y a 3 nouveaux paramètres. Il y a le biais b et un vecteur de poids W . Ce sont ces deux paramètres que l'IA devra apprendre et seront modifiés. Il y a aussi σ qui correspond à la fonction d'activation. Cette fonction dépend dans notre cas de ce à quoi la sortie correspond. Avec les problèmes P_1 et P_2 , on a respectivement une sortie de classification mono-classe et une sortie de classification à 3 classes. Ainsi, on va respectivement utiliser Sigmoid et Softmax comme fonction d'activation.

Sigmoid est très adaptée pour prédire des classes qui sont indépendantes (par exemple : prédire si c'est une image de fruit ou non et si c'est un objet vertical ou non). On peut interpréter la sortie de cette fonction comme la probabilité de la prédiction : elle transforme les valeurs dans \mathbb{R} vers l'intervalle $[0 ; 1]$. Elle se calcule de la façon suivante :

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$




Figure 34 : Graphe de Sigmoid

Softmax quant à elle est très adaptée pour prédire plusieurs classes qui ne sont pas dépendantes (par exemple : prédire si c'est une image de piéton, de voiture, de bus, de camion ou d'autre chose). Elle se calcule de la façon suivante :

$$\sigma(z_i) = \frac{e^{z_i}}{\sum_{i=1}^n e^{z_i}}$$

Elle a la particularité de mettre en avant la classe prédite comme sur l'image ci-dessous.




Figure 35 : Histogrammes des valeurs des neurones de sortie avant et après Softmax

Pour les deux problèmes, on utilise les mêmes entrées : le mode et la fréquence de résonnance associées. Après entraînement sur un set de données dédié, on mesure la performance en calculant la précision des prédictions faites sur un set de test que le perceptron n'a jamais vu. Pour P_1 , la précision est de 92,16%. Pour P_2 , elle est de 54,9% seulement.

3) Arbre de décision

Un arbre de décision est une succession de nœuds parents se divisant en deux nœuds enfants en comparant une valeur critère X_c parmi l'entrée X par rapport à une valeur seuil s . Le schéma ci-dessous résume ce passage de nœud parent à l'un des deux nœuds enfants.




Figure 36 : Schéma de passage de nœud parent à nœud enfant

Ici, l'IA doit apprendre l'index du critère (c) et le seuil (s) pour chaque passage. Pour cela, on cherche à minimiser un indice dans les nœuds appelé l'impureté Gini qui se calcule comme suit :

$$Gini\ impurity = 1 - \sum_{i=0}^k p_i^2$$

Où k représente le nombre de sorties et p la proportion des séparations par rapport au nombre d'éléments dans le nœud parent.




Figure 37 : Exemple d'arbre de décision avec les détails

Contrairement au perceptron, cette fois, les entrées utilisées sont des images en couleurs de 1615x677 qui vont devoir être vectorisées. Cela fait que les vecteurs d'entrée de l'arbre de décision seront de dimension 3 280 065, ce qui est beaucoup trop. On va chercher à réduire ces images de dimensions.

Pour ce faire, on va faire du Maxpooling en deux dimensions. Cette opération revient à regarder une matrice au travers d'une fenêtre de dimensions définies (ici, de 2x2), de ne retenir que la plus grande valeur et de répéter l'opération en déplaçant la fenêtre par un certain pas (ici, de 2 dans chaque dimension).




Figure 38 : Exemple de Maxpooling en 2D

Grâce à cette méthode, on passe d'une image de 1615x667 à une image de 42x100 en répétant quatre fois l'opération, ce qui donne un vecteur de dimension 12 600. On a réduit l'image de près de 260 fois. Même si l'image à l'air de se dégrader, elle conserve ses principales caractéristiques comme la forme et le dégradé de couleur. C'est comme si, pour nous humains, on essayait de faire un même travail à partir de ces images mais la résolution de l'écran (et donc des images) est plus petite que celle dont on a l'habitude.




Figure 39 : Image originale (à gauche) et image réduite (à droite)

De la même manière que pour le perceptron, on mesure la performance de l'arbre de décision en calculant la précision des prédictions faites sur un set de test. Pour P_1 , la précision est de 98,72%. Pour P_2 , elle est de 92,71%.

Conclusion

Si on devait faire un choix entre les deux solutions présentées pour résoudre P_1 , on peut choisir celle que l'on veut mais avec une préférence pour l'arbre de décision. Pour P_2 , le perceptron est à éviter.

En somme, l'arbre de décision est la meilleure solution à prendre. Cependant, lors d'une utilisation en situation réelle, cette solution n'est pas applicable. Pour qu'elle le soit, il faudrait extraire l'image de la déformée du matériau sur Patran-Nastran, ce qui implique que l'on sache modéliser le matériau à tester. Cela n'a alors pas de sens de tester le matériau puisqu'on le connaît.

Pour conclure, en situation réelle, seul le perceptron pour résoudre P_1 est programmable tel quel. Il serait possible de rendre l'arbre de décision utilisable si on utilise d'autres images en entrées qui elles sont obtenables sans devoir connaître le matériau au préalable.